



# Υλοποίηση Αλγορίθμου Χρονοπρογραμματισμού (Task Scheduler) στον Linux Kernel (Έκδοση 6.14.8)

Λαζανάς Αλέξιος lazanas.ale@gmail.com

February 2, 2026



LINUXSIMPLY



# Contents

|          |                                                                                     |           |
|----------|-------------------------------------------------------------------------------------|-----------|
| <b>0</b> | <b>Σχόλια και Παραδοχές</b>                                                         | <b>3</b>  |
| <b>1</b> | <b>Περιγραφή του Αλγορίθμου Χρονοπρογραμματισμού</b>                                | <b>4</b>  |
| <b>2</b> | <b>Λίγα Λόγια για την δομή του Χρονοπρογραμματιστή στον Linux Kernel</b>            | <b>5</b>  |
| 2.1      | Αντικειμενοστρέφεια και Κληρονομικότητα στην C; . . . . .                           | 5         |
| 2.2      | Η "Αφηρημένη Κλάση" του Χρονοπρογραμματιστή στο Linux Kernel . . . . .              | 6         |
| 2.3      | Πως αποθηκεύονται οι διεργασίες και οι διαφορετικοί Χρονοπρογραμματιστές; . . . . . | 7         |
| 2.3.1    | Δομή της task_struct . . . . .                                                      | 7         |
| 2.3.2    | Η αποθήκευση των Χρονοπρογραμματιστών . . . . .                                     | 7         |
| 2.4      | Επιλογή του επόμενου task . . . . .                                                 | 8         |
| <b>3</b> | <b>Διαλέγοντας τον Χρονοπρογραμματιστή για μια Διεργασία</b>                        | <b>9</b>  |
| <b>4</b> | <b>Η υλοποίηση της νέας πολιτικής στον Linux kernel</b>                             | <b>10</b> |
| 4.1      | Επιπρόσθετες κλήσεις συστήματος (system calls) . . . . .                            | 10        |
| 4.2      | Enquing and dequeing a Task . . . . .                                               | 12        |
| 4.3      | Επιλέγοντας το επόμενο Task . . . . .                                               | 15        |
| 4.4      | Ρυθμίζοντας το προηγούμενο task και καθορίζοντας το επόμενο task . . . . .          | 16        |
| 4.5      | Προεκτόπιση Διεργασιών . . . . .                                                    | 17        |
| 4.6      | Ένα task τερματίζει . . . . .                                                       | 18        |
| <b>5</b> | <b>Τεστάροντας τον Χρονοπρογραμματιστή</b>                                          | <b>19</b> |
| 5.1      | Testing Environment . . . . .                                                       | 19        |
| 5.2      | Testbench Used . . . . .                                                            | 19        |
| 5.3      | Test Results . . . . .                                                              | 20        |
| <b>6</b> | <b>Έκδοση 2η: Επιλογή CPU και Process-Migration</b>                                 | <b>24</b> |
| <b>7</b> | <b>Sources and Citations</b>                                                        | <b>26</b> |

## 0 Σχόλια και Παραδοχές

- Για την υλοποίηση του πρότζεκτ έχει χρησιμοποιηθεί η έκδοση 6.14.8 του linux kernel
- Για την οπτικοποίηση των στοιχείων κάθε διεργασίας όταν εκείνη τελειώνει σε ραβδογράμματα, τα στοιχεία της διεργασίας αντιγράφονται από το debug pipe (/sys/kernel/debug/tracing/trace) σε csv αρχείο μέσω του shell script `process_data_visualization/copy_to_csv.sh`.
- Το προαναφερθέν csv διαβάζεται από ένα python script που μέσω της matplotlib εμφανίζει τα κατάλληλα ραβδογράμματα. Για την συγγραφή του κώδικα του python script, ευχαριστώ πολύ για την συνεισφορά της την Σταματία Καλημέρη (stamykalim@gmail.com).
- Από την έκδοση 6.11 και έπειτα η συγγραφή και η ενσωμάτωση scheduling αλγορίθμων στο linux kernel είναι ευκολότερη και ασφαλέστερη μέσω της προσθήκης της `extensible_sched_class` και πλέον μπορεί κανείς να προσθέσει schedulers μέσα από loadable bpf modules. Στο συγκεκριμένο πρότζεκτ επέλεξα να ακολουθήσω την "old school" μέθοδο επεκτείνοντας τον κώδικα του kernel απ' ευθείας, μπορεί αυτή η μέθοδος να απαιτεί μεγαλύτερο κόπο, αλλά θεωρώ ότι δίνει πιο στέρεη εκπαιδευτική εμπειρία.

# 1 Περιγραφή του Αλγορίθμου Χρονοπρογραμματισμού

Ο Αλγόριθμος χρονοπρογραμματισμού που υλοποιήσα είναι πολύ απλός. Κάθε διεργασία έχει δύο dealines  $D1$  και  $D2$  με  $D1 < D2$  και εκτιμώμενο χρόνο εκτέλεσης  $X$  ο οποίος πρέπει να μπορεί να ολοκληρωθεί εντός των deadlines. Τα τρία πεδία αυτά προσδίδονται στην τρέχουσα διεργασία μέσω μιας νέας κλήσης συστήματος (system call) που όρισα. Στην συνέχεια ο scheduler υπολογίζει το σκορ της διεργασίας με βάση αυτά τα τρία πεδία ως εξής: Αν ο εκτιμώμενος χρόνος εκτέλεσης δείχνει ότι η διεργασία θα τελειώσει πριν την χρονική στιγμή  $D1$  τότε το σκορ είναι 100, αντίθετα αν μας πληροφορεί ότι θα τελειώσει μετά από την  $D2$  τότε το σκορ είναι 0. Αν μας πληροφορεί ότι θα τελειώσει μεταξύ των χρονικών στιγμών  $D1$  και  $D2$  υπολογίζεται από τον τύπο:  $\frac{D2-X}{D2-D1} * 100$ .

Ο scheduler θα επιλέξει για να τρέξει την διεργασία με το μέγιστο σκορ και θα της δώσει χρονομερίδιο ανάλογο του σκορ της. Μετά από την λήξη του χρονομεριδίου το σκορ μειώνεται με ρυθμό ανάλογο του χρόνου που έχει καταναλώσει στην cpu μέχρι στιγμής. Αν η διεργασία ξεπεράσει ως χρόνο εκτέλεσης εκείνον που δήλωσε στα system calls της δίνεται πέναλι μειώνοντας το σκορ κατά το τετράγωνο της διαφοράς του χρόνου που έχει τρέξει με τον χρόνο που υποσχέθηκε ότι θα τρέξει.

Η προεκτόπιση (preemption) γίνεται με την λήξη του χρονομεριδίου. Σε περίπτωση που η τρέχουσα διεργασία έχει ξεπεράσει τον χρόνο που υποσχέθηκε και μια άλλη μόλις έγινε runnable από μπλοκαρισμένη η οποία έχει μεγαλύτερο σκορ τότε γίνεται επίσης προεκτόπιση της τρέχουσας διεργασίας.

## 2 Λίγα Λόγια για την δομή του Χρονοπρογραμματιστή στον Linux Kernel

### 2.1 Αντικειμενοστρέφεια και Κληρονομικότητα στην C;

Ο τίτλος της υποπαραγράφου ίσως να φαίνεται πρωτοφανής καθώς όλοι γνωρίζουμε ότι η γλώσσα C υποστηρίζει διαδικαστικό προγραμματισμό, όχι αντικειμενοστρεφή.

Ας δούμε ένα παράδειγμα κληρονομικότητας σε μια γνωστή αντικειμενοστρεφή γλώσσα όπως η Java.

```
abstract class ExampleClass {
    public abstract int someMethod(int someArgument);
}

public class Main {
    public static void main(String [] args){
        ExampleClass exampleInstance = new ExampleClass {
            public int someMethod(int someArgument) {
                System.out.println("Here_is_my_argument:"+someArgument);
            }
        }
    }
}
```

Το παραπάνω παράδειγμα κληρονομικότητας πρακτικά είναι το μοναδικό που μπορεί να μεταφερθεί αυτούσιο στην γλώσσα C ως εξής:

```
struct ExampleClass {
    int (*someMethod)(int someArgument);
};

int someMethod_impl(int someArgument){
    printf("Here_is_my_argument:%d\n",someArgument);
}

struct ExampleClass exampleInstance = {
    .someMethod = someMethod_impl
};
```

Ο linux kernel είναι γραμμένος σε GNU C (επειδή για αρκετά low level parts απαιτείται να εισάγουμε inline assembly που μόνο το GNU C πρότυπο επιτρέπει). Όμως σε κάποια μέρη, όπως η δομή των character αρχείων και οι χρονοπρογραμματιστές, με τους οποίους ασχολήθηκα στο παρόν πρότζεκτ, είναι χρήσιμη μια πιο αντικειμενοστρεφής προσέγγιση και συμπεριφορά. Με τον τρόπο που μόλις εξηγήθηκε ο kernel του linux ενσωματώνει την αντικειμενοστρεφή προσέγγιση στον κώδικά του.

Η δομή αυτή που ακολουθείται στους χρονοπρογραμματιστές μας δίνει την δυνατότητα να επεκτείνουμε και να δημιουργήσουμε νέους αλγορίθμους scheduling με αρκετή ευκολία και μικρή επέμβαση στον κώδικα του linux kernel.

## 2.2 Η "Αφηρημένη Κλάση" του Χρονοπρογραμματιστή στο Linux Kernel

Έχοντας αντιληφθεί πλέον πως μπορούμε να εξομοιώσουμε την αντικειμενοστρεφή προσέγγιση στην γλώσσα C, είναι πλέον κατάλληλο να ρίξουμε μια ματιά στον κώδικα της αφηρημένης κλάσης του χρονοπρογραμματιστή (`struct sched_class`)

```
struct sched_class {
#ifdef CONFIG_UCLAMP_TASK
    int uclamp_enabled;
#endif

    void (*enqueue_task)(struct rq *rq, struct task_struct *p, int flags);
    bool (*dequeue_task)(struct rq *rq, struct task_struct *p, int flags);
    void (*yield_task)(struct rq *rq);
    bool (*yield_to_task)(struct rq *rq, struct task_struct *p);

    void (*wakeup_preempt)(struct rq *rq, struct task_struct *p, int flags);

    int (*balance)(struct rq *rq, struct task_struct *prev, struct rq_flags *rf);
    struct task_struct *(*pick_task)(struct rq *rq);
    /*
     * Optional! When implemented pick_next_task() should be equivalent to:
     *
     * next = pick_task();
     * if (next) {
     *     put_prev_task(prev);
     *     set_next_task_first(next);
     * }
     */
    struct task_struct *(*pick_next_task)(struct rq *rq, struct task_struct *prev);

    void (*put_prev_task)(struct rq *rq, struct task_struct *p, struct task_struct *next);
    void (*set_next_task)(struct rq *rq, struct task_struct *p, bool first);

#ifdef CONFIG_SMP
    int (*select_task_rq)(struct task_struct *p, int task_cpu, int flags);

    void (*migrate_task_rq)(struct task_struct *p, int new_cpu);

    void (*task_woken)(struct rq *this_rq, struct task_struct *task);

    void (*set_cpus_allowed)(struct task_struct *p, struct affinity_context *ctx);

    void (*rq_online)(struct rq *rq);
    void (*rq_offline)(struct rq *rq);

    struct rq *(*find_lock_rq)(struct task_struct *p, struct rq *rq);
#endif

    void (*task_tick)(struct rq *rq, struct task_struct *p, int queued);
    void (*task_fork)(struct task_struct *p);
    void (*task_dead)(struct task_struct *p);

    /*
     * The switched_from() call is allowed to drop rq->lock, therefore we
     * cannot assume the switched_from/switched_to pair is serialized by
     * rq->lock. They are however serialized by p->pi_lock.
     */
    void (*switching_to)(struct rq *this_rq, struct task_struct *task);
    void (*switched_from)(struct rq *this_rq, struct task_struct *task);
    void (*switched_to)(struct rq *this_rq, struct task_struct *task);
    void (*reweight_task)(struct rq *this_rq, struct task_struct *task,
                          const struct load_weight *lw);
    void (*prio_changed)(struct rq *this_rq, struct task_struct *task,
                        int oldprio);

    unsigned int (*get_rr_interval)(struct rq *rq,
                                    struct task_struct *task);

    void (*update_curr)(struct rq *rq);

#ifdef CONFIG_FAIR_GROUP_SCHED
    void (*task_change_group)(struct task_struct *p);
#endif

#ifdef CONFIG_SCHED_CORE
    int (*task_is_throttled)(struct task_struct *p, int cpu);
#endif
};
```

Κάθε αλγόριθμος χρονοπρογραμματισμού που υπάρχει στο linux kernel είναι στην ουσία αντικείμενο αυτής της κλάσης που υλοποιεί μεγάλο μέρος αυτών των μεθόδων, δεν είναι απολύτως απαραίτητο να υλοποιηθούν όλες, κάποιοι από αυτούς τους pointers είναι πιθανό να παραμείνουν NULL σε κάποια instances.

## 2.3 Πως αποθηκεύονται οι διεργασίες και οι διαφορετικοί Χρονοπρογραμματιστές;


### 2.3.1 Δομή της task\_struct

Στο linux kernel υπάρχει η struct task\_struct που στην ουσία ορίζει την δομή μιας διεργασίας. Είναι πρακτικά πάρα πολύ μεγάλη σε χώρο struct, για αυτό τον λόγο δεν αποθηκεύεται εκείνη στην ουρά αλλά μόνο το μέρος της που είναι απαραίτητο για το scheduling και μέσω του macro container\_of() του linux kernel μπορούμε από έναν pointer σε ένα μέλος ενός αντικειμένου να επιστρέψουμε έναν pointer στο ευρύτερο αντικείμενο.

Η struct αυτή περιέχει όλα τα δεδομένα που υπάρχουν για μια διεργασία ή ένα thread (το Linux δεν έχει ξεχωριστή δομή για threads). Είναι πραγματικά τεράστια σε χώρο και κώδικα, χρησιμοποιείται μόνο όταν είναι απολύτως απαραίτητη και μόνο μέσω pointers σε αντικείμενά της. Τα αντικείμενα της task\_struct είναι αποθηκευμένα στο kernel heap memory, λόγω του μικρού μεγέθους της kernel stack στην στοίβα αποθηκεύονται μόνο pointers σε αντικείμενα τα οποία, αυτούσια είναι στον heap.

### 2.3.2 Η αποθήκευση των Χρονοπρογραμματιστών


Το linux έχει από μόνο του 5 instances της κλάσης sched\_class υλοποιώντας 5 διαφορετικούς scheduling αλγόριθμους για 5 διαφορετικές κατηγορίες διεργασιών. Τα 5 αυτά instances αποθηκεύονται στο kernel-data-memory (ως καθολικές μεταβλητές) και ένα array από pointers σε αυτά αποθηκεύεται στην kernel-stack. Στο array αυτό οι pointers στους schedulers είναι αποθηκευμένοι με την σειρά που δείχνει η παρακάτω εικόνα:



οι pointers `__sched_class_highest` και `__sched_class_lowest` είναι στην ουσία ίσοι με `&__stop_sched_class` και `&__idle_sched_class` αντίστοιχα.

Το στιγμιότυπο sched\_class που κατασκεύασα εγώ (hvf\_sched\_class) το τοποθέτησα στο array μετά από την fair\_sched\_class και πριν από την idle\_sched\_class.

Σε παλιότερες εκδόσεις του linux kernel η struct sched\_class είχε ένα ακόμα data member τύπου (struct sched\_class \*next) που και οι διαφορετικοί schedulers αποθήκευαν οι ίδιοι σε συνδεδεμένη λίστα την σειρά με την οποία θα έτρεχαν όπως παρακάτω:



Αλλά αυτό για λόγους efficiency άλλαξε από την έκδοση 5.9 και έπειτα και μετάβηκαν στο μοντέλο που εξήγησα παραπάνω.

## 2.4 Επιλογή του επόμενου task

Η βασική scheduling λογική βρίσκεται στην συνάρτηση `__pick_next_task` στο αρχείο `kernel/sched/core.c`. Πρακτικά διατρέχουμε όλο το array με τους διαφορετικούς schedulers και καλούμε την συνάρτηση `pick_next_task()` για καθέναν από αυτούς (που όπως δείξαμε παραπάνω είναι μια συνάρτηση που υλοποιούν όλοι οι schedulers).

Από προεπιλογή όλες οι διεργασίες αν δεν διαλέξουν οι ίδιες τον χρονοπρογραμματιστή ο οποίος θα τις διαχειρίζεται αωατίθενται στο instance `fair_sched_class` που είναι ο default χρονοπρογραμματιστής του linux. Συνεπώς υπάρχει ένα optimization ότι αν όλες οι τρέχουσες διεργασίες είναι στην `fair_sched_class` να μην κοιτάζει καν τις υπόλοιπες και να τρέξει εκείνη που θα κάνει schedule η fair.

```

static inline struct task_struct *
__pick_next_task(struct rq *rq, struct task_struct *prev, struct rq_flags *rf)
{
    const struct sched_class *class;
    struct task_struct *p;

    rq->dl_server = NULL;

    if (scx_enabled())
        goto restart;

    /*
     * Optimization: we know that if all tasks are in the fair class we can
     * call that function directly, but only if the @prev task wasn't of a
     * higher scheduling class, because otherwise those lose the
     * opportunity to pull in more work from other CPUs.
     */
    if (likely(!sched_class_above(prev->sched_class, &fair_sched_class) &&
        rq->nr_running == rq->cfs.h_nr_queued)) {
        p = pick_next_task_fair(rq, prev, rf);
        if (unlikely(p == RETRY_TASK))
            goto restart;

        /* Assume the next prioritized class is idle_sched_class */
        if (!p) {
            p = pick_task_idle(rq);
            put_prev_set_next_task(rq, prev, p);
        }

        return p;
    }

restart:
    prev_balance(rq, prev, rf);

    for_each_active_class(class) {
        if (class->pick_next_task) {
            p = class->pick_next_task(rq, prev);
            if (p)
                return p;
        } else {
            p = class->pick_task(rq);
            if (p) {
                put_prev_set_next_task(rq, prev, p);
                return p;
            }
        }
    }

    BUG(); /* The idle class should always have a runnable task. */
}

```

### 3 Διαλέγοντας τον Χρονοπρογραμματιστή για μια Διεργασία

Όπως αναφέρθηκε νωρίτερα μια διεργασία έχει την δυνατότητα καθώς τρέχει να διαλέξει τον χρονοπρογραμματιστή στον οποίο θα ανατεθεί καθώς και να τον αλλάζει κατ' απαίτηση. Όλες οι διεργασίες έχουν έναν default χρονοπρογραμματιστή με την πλειοψηφία αυτών να έχει τον fair ως προεπιλογή. Πώς όμως μπορεί μια διεργασία να διαλέξει τον scheduler στον οποίο θα ανατεθεί στην συνέχεια και να τον αλλάξει on demand?

Το linux παρέχει ήδη μια κλήση συστήματος για αυτή την λειτουργία η οποία είναι δηλωμένη για C user-space προγράμματα στο header file `include uapi/linux/sched.h` και μπορεί οποιοδήποτε C πρόγραμμα να συμπεριλάβει αυτό το Header ως εξής `#include <linux/sched.h>`. Η κλήση συστήματος αυτή είναι η `sched_setscheduler()`, η οποία παίρνοντας όρισμα το pid της επιθυμητής διεργασίας (αν είναι 0 λειτουργεί για την διεργασία που κάλεσε το system call), την σταθερά που καθορίζει τον αλγόριθμο χρονοπρογραμματισμού (`SCHED_FIFO` (αναθέτει στον `rt_sched_class` με άπειρο χρονομερίδιο (Αλγόριθμος FCFS)), `SCHED_RR` (αναθέτει στον `rt_sched_class` με περιορισμένο χβάντο χρόνου (Αλγόριθμος Round Robin)), `SCHED_NORMAL` (αναθέτει στον `fair_sched_class` (Αλγόριθμος CFS (DEFAULT))) και έναν δείκτη σε ένα `sched_attribute` (μπορεί να είναι NULL) αλλάζει τον scheduler της διεργασίας και την αναθέτει στον επιθυμητό.

Εγώ αφού όρισα την δική μου σταθερά (`SCHED_HVF`) έκανα την αντιστοίχιση στην κλάση `hvf_sched_class` και στην ουσία στο linux σύστημα που έχει τον custom kernel που έφτιαξα είναι ικανό να αντιστοιχίσει μια οποιαδήποτε διεργασία και στον δικό μου scheduler βάζοντας ως όρισμα την σταθερά που όρισα (τιμή 8).

## 4 Η υλοποίηση της νέας πολιτικής στον Linux kernel

Η υλοποίηση ουσιαστικά του νέου scheduling αλγορίθμου απαιτούσε αρκετές φορές την προσθήκη κώδικα σε ήδη υπάρχουσες συναρτήσεις και structs στο Linux kernel. Όλα τα αρχεία που χρειάστηκε να επεξεργαστώ κατά την υλοποίηση βρίσκονται στο github repo που έφτιαξα. Προφανώς στο παρόν έγγραφο θα αναφερθώ μόνο στα κομμάτια κώδικα που είναι απολύτως βασικά για την υλοποίηση του αλγορίθμου μου όχι ιδιαίτερα για την καταγραφή και την ενσωμάτωσή του στο linux kernel, καθώς αυτός ο κώδικας είναι πιο πολύ κομποραπτική και θα έλεγα ότι αν κάποιος θέλει να φτιάξει ένα αντίστοιχο πρότζεκτ αυτό είναι το εύκολο μέρος του.

### 4.1 Επιπρόσθετες κλήσεις συστήματος (system calls)

Για την υλοποίηση του scheduler προστέθηκαν 4 ακόμα πεδία στην task\_struct (αυτά που συζητήθηκαν στην αρχή του αλγορίθμου + μια boolean τιμή που καθορίζει αν τα πεδία αυτά έχουν καθοριστεί από τον χρήστη (μέσα από την κλήση συστήματος που δημιουργήσα)

```
#include <linux/kernel.h>
#include <linux/sched.h>
#include <linux/my_sched_sys.h>
#include <asm/current.h>
#include <asm-generic/errno.h>
#include <linux/syscalls.h>
#include <linux/uaccess.h>
#include <linux/types.h>
#include <linux/timekeeping.h>

#define M 1000
#define H 100

SYSCALL_DEFINE3(set_scheduling_params, long, deadline_1, long, deadline_2, long, computation_time){
    bool condition_1 = (deadline_1>0 && deadline_2>0) && deadline_1<deadline_2;
    struct timespec64 now;
    ktime_get_real_ts64(&now);

    bool condition_2 = (now.tv_sec*M+computation_time)<deadline_2*M;

    if (condition_1 && condition_2){
        current->deadline_1 = deadline_1;
        current->deadline_2 = deadline_2;
        current->computation_time = computation_time;
        current->pars_set = true;

        return 0;
    }
    return -EINVAL;
}

SYSCALL_DEFINE1(get_scheduling_params, struct d_params *, params){
    bool condition = (params!=NULL) && access_ok(params, sizeof(struct d_params));
    if (condition){
        if (copy_to_user(&params->deadline_1, &current->deadline_1, sizeof(long))!=0){
            return -EFAULT;
        }
        if (copy_to_user(&params->deadline_2, &current->deadline_2, sizeof(long))!=0){
            return -EFAULT;
        }
        if (copy_to_user(&params->computation_time, &current->computation_time, sizeof(long))!=0){
            return -EFAULT;
        }
        return 0;
    }
    return -EINVAL;
}
```

Με το πρώτο system call η τρέχουσα διεργασία καθορίζει τις παραμέτρους της ενώ με το δεύτερο επιστρέφονται οι παράμετροί της. Έγραψα και ένα τρίτο system call που επιστρέφει το σκορ που θα είχε η διεργασία αν τελείωνε την στιγμή που κάλεσε αυτό το syscall

```

SYSCALL_DEFINE0(get_scheduling_score){
    struct timespec64 now;
    ktime_get_real_ts64(&now);
    long D1 = current->deadline_1;
    long D2 = current->deadline_2;
    long D3 = now.tv_sec;

    if (D3<D1)
        return H;
    else if (D2<D3)
        return 0;
    else
        return ((D2-D3)*100)/(D2-D1);
}

```

## 4.2 Enqueing and dequeing a Task

Σύμφωνα με την πολιτική όπως αναλύθηκε στην αρχή του παρόντος εγγράφου ο scheduler θα επιλέξει πάντα την διεργασία με το μέγιστο σκορ για να τρέξει. Οπότε θα μας ήταν χρήσιμη μια δομή δεδομένων που γρήγορα έχει την ικανότητα να επιστρέψει το task με το μέγιστο σκορ, μια τέτοια δομή θα ήταν ο σωρός (heap) όμως ο σωρός είναι inefficient σε arbitrary deletion σε περίπτωση που ένα task μπλοκάρει λόγω I/O ή λόγω κλήσης της sleep. Συνεπώς επέλεξα μια δομή δεδομένων που είναι ικανή να εκτελέσει αποδοτικά και τις δυο αυτές λειτουργίες (σε  $O(\log n)$  χρόνο) ένα υψοζυγισμένο δέντρο δυαδικής αναζήτησης (balanced binary tree) και συγκεκριμένα ένα red-black tree καθώς οι εισαγωγές και οι διαγραφές είναι πιο συχνές σε ένα scheduling context και τις χειρίζεται πιο αποδοτικά από την εναλλακτική του (το AVL Tree).

Ο linux kernel διαθέτει ένα ήδη ορισμένο header file με την υλοποίηση ενός red-black tree στο include/linux/rbtree.h αυτό το red-black tree χρησιμοποίησα για την υλοποίηση της runqueue του αλγορίθμου χρονοπρογραμματισμού μου. Στο δέντρο αποθηκεύω αντικείμενα τύπου sched\_hvf\_entity με κριτήριο το scheduling score τους.

Παρακάτω βρίσκονται όλες οι συναρτήσεις που συμβάλλουν στην εισαγωγή ενός sched\_hvf\_entity στην runqueue του χρονοπρογραμματιστή μου.

```
static void
enqueue_task_hvf(struct rq *rq, struct task_struct *p, int flags) {
    struct hvf_rq *hvf_rq = &rq->hvf;
    struct sched_hvf_entity *se_hvf = &p->hvf;

    if (flags & (ENQUEUE_INITIAL | ENQUEUE_CHANGED)) {
        give_default_hvf_values(p);
        init_sched_hvf_entity(se_hvf);
        compute_init_sched_value(p);
    }

    else if (flags & (ENQUEUE_WAKEUP | ENQUEUE_MIGRATED | ENQUEUE_RESTORE)) {
        compute_init_sched_value(p);
    }

    if (se_hvf != hvf_rq->curr && !se_hvf->on_rq) {
        enqueue_hvf_entity(hvf_rq, se_hvf);
        rq->nr_running++;
    }
}

inline void give_default_hvf_values(struct task_struct *p) {
    if (!p->pars_set) {
        struct timespec64 now;
        ktime_get_real_ts64(&now);
        long curr_time = now.tv_sec + now.tv_nsec/(K*K*K);

        p->deadline_1 = curr_time + 4;
        p->deadline_2 = curr_time + 6;
        p->computation_time = K;
        p->pars_set = true;

        compute_init_sched_value(p);
    }
}

inline void init_sched_hvf_entity(struct sched_hvf_entity *se){
    struct timespec64 now;
    ktime_get_real_ts64(&now);
    se->first_time = now.tv_sec*K + now.tv_nsec/(K*K);
    se->latest_time = se->first_time;
    se->time_used = 0;
    se->cpu_answers = 0;
    se->slice_expired = false;
}

inline long compute_init_sched_value(struct task_struct *p){
    const struct sched_hvf_entity *se_hvf = &p->hvf;
    const long X = se_hvf->first_time*p->computation_time;
    const long V = (X < p->deadline_1*K)? H : (p->deadline_2*K < X)? 0 : (p->deadline_2*K - X)/((p->deadline_2 - p->deadline_1)*K);

    p->hvf.init_sched_value = V;
    p->hvf.curr_sched_value = V;

    return V;
}
```

```

static void enqueue_hvf_entity(struct hvf_rq *hvf_rq, struct sched_hvf_entity *se){
    struct task_struct *task_to_eq = task_hvf_of(se);

    if (exceeded_time(task_to_eq)){
        long ctime = task_to_eq->computation_time;
        penalty_hvf_entity(se, ctime);
    }

    hvf_rq_rbtinsert(&hvf_rq->hvf_task_queue, se);
    hvf_rq->nr_hvf_queued++;
    se->on_rq = true;
    struct sched_hvf_entity *max_entity = hvf_rq->max_value_entity;

    if (!max_entity){
        hvf_rq->max_value_entity = rb_entry(rb_last(&hvf_rq->hvf_task_queue), struct sched_hvf_entity, run_node);
        return;
    }

    if (max_entity->curr_sched_value < se->curr_sched_value)
        hvf_rq->max_value_entity = rb_entry(rb_last(&hvf_rq->hvf_task_queue), struct sched_hvf_entity, run_node);
}

inline long penalty_hvf_entity(struct sched_hvf_entity *se, long ctime){
    long diff = se->time_used - ctime;
    long old_value = se->curr_sched_value;
    long new_value = old_value - (diff*diff*old_value)/100;
    new_value = (new_value>0)? new_value : (old_value == 0)? 10: 0;

    se->curr_sched_value = new_value;
    return new_value;
}

bool hvf_rq_rbtinsert(struct rb_root *root, struct sched_hvf_entity *se){
    struct rb_node **new_node = &(root->rb_node), *parent = NULL;

    while (*new_node != NULL){
        struct sched_hvf_entity *this_entity = container_of(*new_node, struct sched_hvf_entity, run_node);
        int result = se->curr_sched_value - this_entity->curr_sched_value;

        parent = *new_node;
        if (result<=0)
            new_node = &((*new_node)->rb_left);
        else
            new_node = &((*new_node)->rb_right);
    }

    rb_link_node(&se->run_node, parent, new_node);
    rb_insert_color(&se->run_node, root);

    return true;
}

```

Πρακτικά όλες αυτές οι 7 συναρτήσεις υπολογίζουν τα διάφορα γνωρίσματα της κάθε διεργασίας και η hvf\_rq\_rbtinsert εισάγει το sched\_hvf\_entity στην ουρά. Το αντικείμενο με την μέγιστη τιμή cachareται για μεγαλύτερη αποδοτικότητα όταν το χρειαζόμαστε.

Όσον αφορά την εξαγωγή ενός entity από την ουρά οι συναρτήσεις που εμπλέκονται είναι οι παρακάτω:

```

static bool
dequeue_task_hvf(struct rq *rq, struct task_struct *p, int flags){
    struct hvf_rq *hvf_rq = &rq->hvf;
    struct sched_hvf_entity *se_hvf = &p->hvf;

    if (se_hvf != hvf_rq->curr && se_hvf->on_rq){
        bool result = dequeue_hvf_entity(hvf_rq, se_hvf);
        rq->nr_running--;
        return result;
    }

    if (se_hvf == hvf_rq->curr && !task_is_running(p)){
        bool result = true;

        if (unlikely(se_hvf->on_rq))
            result = dequeue_hvf_entity(hvf_rq, se_hvf);

        rq->nr_running--;
        hvf_rq->curr = NULL;

        return result;
    }

    return false;
}

```

```

static bool dequeue_hvf_entity(struct hvf_rq *hvf_rq, struct sched_hvf_entity *se){
    struct rb_node *max_node = &hvf_rq->max_value_entity->run_node;

    if (max_node == &se->run_node){
        struct rb_node *prev_node = rb_prev(&se->run_node);
        hvf_rq->max_value_entity = (prev_node!=NULL)? rb_entry(prev_node, struct sched_hvf_entity, run_node) : NULL;
    }

    rb_erase(&se->run_node, &hvf_rq->hvf_task_queue);
    RB_CLEAR_NODE(&se->run_node);
    hvf_rq->nr_hvf_queued--;
    se->on_rq = false;

    return true;
}

```

Το μοτίβο της εξαγωγής είναι ίδιο με εκείνο στην εισαγωγή και οι συναρτήσεις αυτές βεβαιώνουν πάντα ότι θα cachάρεται το entity με το μέγιστο σχορ. Είναι βελτιστοποιημένες ώστε να ενημερώνουν το entity με την μέγιστη τιμή μόνο όταν είναι χρήσιμο.

### 4.3 Επιλέγοντας το επόμενο Task

Για να διαλέξω το επόμενο task αρκεί απλά να επιστρέψω το task που αντιστοιχεί στο μέγιστο entity που έχω cacheάει ως data member στην hvf\_rq. Το γεγονός ότι κατά την εισαγωγή και την διαγραφή των tasks αποθηκεύω ξεχωριστά το μέγιστο entity με βοηθά να έχω διαθέσιμο το επόμενο task χωρίς να διατρέχω συνέχεια ολόκληρο το δέντρο για να το εντοπίσω.

Παρακάτω βρίσκονται όλες οι συναρτήσεις που εμπλέκονται στην επιλογή του επόμενου task.

```
static struct task_struct *pick_task_hvf(struct rq *rq){
    struct sched_hvf_entity *se_hvf;
    struct hvf_rq *hvf_rq;

    hvf_rq = &rq->hvf;
    if (hvf_rq_empty(hvf_rq))
        return rq->idle;
    se_hvf = pick_entity_hvf(hvf_rq);
    return task_hvf_of(se_hvf);
}

inline bool hvf_rq_empty(struct hvf_rq *hvf_rq){
    struct rb_root *root = &hvf_rq->hvf_task_queue;
    return RB_EMPTY_ROOT(root);
}

static inline
struct sched_hvf_entity *pick_entity_hvf(struct hvf_rq *hvf_rq){
    return hvf_rq->max_value_entity;
}
```

Στην ουσία επιστρέφεται απλά η μέγιστη entity. Όταν όμως η ουρά είναι άδεια επιστρέφουμε το Idle task για να τοποθετήσουμε τον scheduler σε αναμονή ώστε να αναμένει την άφιξη ενός νέου προς εκτέλεση task (θα μπορούσαμε να επιστρέφουμε και NULL καθώς και σε αυτή την περίπτωση θα επέστρεφε το idle η idle\_sched\_class).

## 4.4 Ρυθμίζοντας το προηγούμενο task και καθορίζοντας το επόμενο task

Όπως είδαμε παραπάνω, η `pick_next_task_hvf` καλεί τις συναρτήσεις `put_prev_task` και `set_next_task` σε περίπτωση που επιστραφεί ένα έγκυρο task από την `pick_task` αυτές οι συναρτήσεις είναι υπεύθυνες να τοποθετήσουν το προηγούμενο task στην ουρά ξανά αν χρειάζεται (`put_prev_task`) και να βγάλουν από την ουρά το επόμενο και να το θέσουν ως τρέχον στην cpu (`set_next_task`).

Οι υλοποιήσεις των δυο αυτών συναρτήσεων στον scheduling αλγόριθμο που έφτιαξα είναι οι παρακάτω:

```
static void
set_next_hvf_entity(struct hvf_rq *hvf_rq, struct sched_hvf_entity *se){
    if (se->on_rq)
        dequeue_hvf_entity(hvf_rq, se);

    update_latest_se_hvf(se);

    hvf_rq->curr = se;
}

static void set_next_task_hvf(struct rq *rq, struct task_struct *p, bool first){
    struct sched_hvf_entity *se_hvf = &p->hvf;
    struct hvf_rq *hvf_rq = &rq->hvf;
    if (!first)
        return;

    set_next_hvf_entity(hvf_rq, se_hvf);
}

/*
 * this function shall be called
 * in put_prev_task for the previous task to register the time it used the CPU
 */

inline void update_used_se_hvf(struct sched_hvf_entity *se) {
    struct timespec64 now;
    ktime_get_real_ts64(&now);

    long current_time = now.tv_sec*K + now.tv_nsec/(K*K);
    se->time_used += current_time - se->latest_time;
}

static void
put_prev_hvf_entity(struct hvf_rq *hvf_rq, struct sched_hvf_entity *se) {
    if (!se->on_rq)
        enqueue_hvf_entity(hvf_rq, se);

    hvf_rq->curr = NULL;
}

static void put_prev_task_hvf(struct rq *rq, struct task_struct *prev, struct task_struct *next) {
    struct sched_hvf_entity *prev_hvf = &prev->hvf;
    struct hvf_rq *hvf_rq = &rq->hvf;
    update_used_se_hvf(prev_hvf);

    if (task_is_running(prev)) {
        if (prev_hvf->slice_expired) {
            reduce_sched_value(prev_hvf);
            prev_hvf->slice_expired = false;
        }
        put_prev_hvf_entity(hvf_rq, prev_hvf);
    }
}
```

## 4.5 Προεκτόπιση Διεργασιών

Ο αλγόριθμός μου βασίζεται σε δυναμικά χρονομερίδια όπου με την λήξη αυτών γίνεται η προεκτόπιση της τρέχουσας διεργασίας. Προεκτόπιση γίνεται απιπλέον και όταν γίνεται runnable μια διεργασία η οποία και η τρέχουσα έχει ξεπεράσει τον χρόνο που υποσχέθηκε, η τρέχουσα θα προεκτοπιστεί. Οι συναρτήσεις που καθορίζουν τότε θα γίνει η προεκτόπιση είναι οι: task\_tick και wakeup\_preempt.

Η συνάρτηση task\_tick καλείται περιοδικά ανά την περίοδο του scheduler που είναι 1ms οπότε τα χρονομερίδια πρέπει κατά κανόνα να είναι της τάξης των millisecond.

```
static void task_tick_hvf(struct rq *rq, struct task_struct *curr, int queued){
    struct sched_hvf_entity *curr_ent = &curr->hvf;
    long slice = time_slice(curr_ent->curr_sched_value);

    curr_ent->runtime += TICK_NSEC;

    if (curr_ent->runtime >= slice*K*K){
        curr_ent->slice_expired = true;
        resched_curr(rq);
    }
}
```

Η κλήση της resched\_curr είναι εκείνη που εκτελεί την προεκτόπιση της τρέχουσας διεργασίας σε περίπτωση που λήξει το χρονομερίδιό της.

Η συνάρτηση wakeup\_preempt καλείται κάθε φορά όπου ένα νέο task μόλις έγινε runnable και μέσω αυτής γίνεται η δεύτερη περίπτωση προεκτόπισης που καθορίζει ο αλγόριθμος.

```
static void wakeup_preempt_hvf(struct rq *rq, struct task_struct *p, int flags){
    if (current->sched_class == &hvf_sched_class){
        struct sched_hvf_entity *curr_se_hvf = &current->hvf;
        struct sched_hvf_entity *p_hvf = &p->hvf;

        /*
         * preempt only if the current task has exceeded its time,
         * else preemption happens generally in time_slice expiration on task_tick_hvf
         */

        if (exceeded_time(current) && (p_hvf->curr_sched_value > curr_se_hvf->curr_sched_value))
            resched_curr(rq);
    }
}
```

## 4.6 Ένα task τερματίζει

όταν μια διεργασία τερματίζει τότε καλείται η `task_dead` που είναι υπεύθυνη να διαγράψει όλες τις αναφορές αυτής της διεργασίας από την μνήμη. Στον δικό μου αλγόριθμο καταγράφει στο kernel debug trace pipe χρήσιμα στοιχεία για αυτήν και έπειτα διαγράφεται από όλες τις δομές δεδομένων στην μνήμη.

```
* static void register_entity_info(struct sched_hvf_entity *se_hvf, int pid){
    long init_value = se_hvf->init_sched_value;
    struct timespec64 now;
    ktime_get_real_ts64(&now);
    long curr_time = now.tv_sec*K + now.tv_nsec/(K*K);

    long turnaround_time = curr_time - se_hvf->first_time;
    long wait_time = turnaround_time - se_hvf->time_used;
    long comp_time = se_hvf->time_used;
    long response_time = se_hvf->cpu_first_answer - se_hvf->first_time;

    trace_printk(
        "hvf_task_terminated,%d,%ld,%ld,%ld,%ld,%ld\n",
        pid,
        init_value,
        turnaround_time,
        wait_time,
        comp_time,
        response_time
    );
}

* static void task_dead_hvf(struct task_struct *p){
    struct rq *rq;
    struct rq_flags rf;
    struct sched_hvf_entity *se_hvf = &p->hvf;

    register_entity_info(se_hvf, p->pid);

    rq = task_rq_lock(p, &rf);

    struct hvf_rq *hvf_rq = &rq->hvf;
    if (se_hvf->on_rq)
        dequeue_hvf_entity(hvf_rq, se_hvf);
    hvf_rq->curr = NULL;

    task_rq_unlock(rq, p, &rf);
}
```

## 5 Τεστάροντας τον Χρονοπρογραμματιστή

Για να τεστάρω τον αλγόριθμο χρονοπρογραμματισμού μου χρειάζομαι πρακτικά ένα testing περιβάλλον ασφαλές, ένα testbench πρόγραμμα που θα spawnήσει πολλές διεργασίες με διαφορετικά σκορ και θα τις αναθέτει στον δικό μου scheduler.

### 5.1 Testing Environment

Για το περιβάλλον πρακτικά χρησιμοποιήθηκε μια εικονική μηχανή που δημιουργήθηκε από το virtual machine manager με λειτουργικό σύστημα lubuntu 24.04 lts, έπειτα αντέγραψα το αρχείο .qcow2 της εικονικής μηχανής σε κάποιον από τους Home folders.

Το Linux έχει την δυνατότητα να μεταφραστεί σε ένα συμπιεσμένο kernel image μέσω της εντολής make bzImage. Αυτό το συμπιεσμένο kernel image μπορώ να το χρησιμοποιήσω ώστε να bootάρω ένα ήδη υπάρχον linux vm με τον δικό μου custom kernel μέσω της εξής εντολής:

```
[alexis-pc linux-testvm]# qemu-system-x86_64 -m 4096 -hda ubuntu24.04.qcow2 -kernel /home/alexis1/Kernels/linux-6.14.8-mod-exec/arch/x86/boot/bzImage -append "root=/dev/sda1 console=ttyS0" -nographic
```

με αυτό τον τρόπο bootάρουμε την εικονική μηχανή με την δική μας έκδοση του linux kernel. Μόλις τρέξουμε την εντολή έχουμε πλέον ανοίξει το τερματικό της εικονικής μηχανής από το τερματικό του υπολογιστή μας. Έτσι μπορούμε να εκτελούμε εντολές σε αυτό το σύστημα χωρίς να χρειάζεται η χρήση μιας πλήρους εικονικής μηχανής (αν και μπορούμε να κάνουμε και αυτό).

Για ευκολία μετέφερα το εκτελέσιμο αρχείο του testbench που περιγράφω στην συνέχεια το οποίο έγινε compiled με το flag static ώστε το εκτελέσιμο να είναι πλήρες και να μην απαιτείται δυναμική φόρτωση μεθόδων.

### 5.2 Testbench Used

Το testbench που χρησιμοποιήθηκε είναι ένα απλό testbench που δημιουργεί 20 διεργασίες με διαφορετικές παραμέτρους η καθεμία και τις αναθέτει να χρονοπρογραμματιστούν από τον δικό μου scheduler.

```
#include <stdio.h>
#include <math.h>
#include <unistd.h>
#include <stdlib.h>
#include <sched.h>
#include <time.h>
#include <sys/syscall.h>
#include <sys/wait.h>

#define DELAY 750
#define K 1000
#define H13 1300

#define SCHED_HVF 0

#define __NR_SET_SCHED_PARS 467
#define __NR_GET_SCHED_PARS 468
#define __NR_GET_SCHED_SCORE 469

#define set_sched_params(x, y, z) syscall(__NR_SET_SCHED_PARS, x, y, z)
#define get_sched_params(x) syscall(__NR_GET_SCHED_PARS, x)

double a = 1.1;

void core_delay(){
    unsigned long j;

    for (j = 0; j < 100000; j++) {
        a += sqrt(1.1)*sqrt(1.2)*sqrt(1.3)*sqrt(1.4)*sqrt(1.5);
        a += sqrt(1.6)*sqrt(1.7)*sqrt(1.8)*sqrt(1.9)*sqrt(2.0);
        a += sqrt(1.1)*sqrt(1.2)*sqrt(1.3)*sqrt(1.4)*sqrt(1.5);
        a += sqrt(1.6)*sqrt(1.7)*sqrt(1.8)*sqrt(1.9);
    }
}

void delay(int workload){
    int i;
    int total_workload = workload*DELAY;

    for (i = 0; i < total_workload; i++)
        core_delay();
}

void do_work(int workload){
    int pid = getpid();

    printf("process %d begins\n", pid);
    delay(workload);
    printf("process %d ends\n", pid);
}
```

```

int main(){
    pid_t procs[20];

    for (int j=0; j<20; ++j){
        procs[j] = fork();
        if (procs[j]<0){
            printf("error in fork\n");
            return 0;
        }
        else if (procs[j] == 0){
            struct sched_param param = {.sched_priority=0};
            long now = time(NULL);
            if (!set_sched_params(now+j+1, now+j+7, K+H13*j)){
                sched_setscheduler(0, SCHED_HVF, &param);
                do_work(j+1);
            }
            else {
                printf("invalid scheduling params\n");
            }
            exit(0);
        }
    }

    for (int j=0; j<20; ++j){
        waitpid(procs[j], NULL, 0);
    }

    return 0;
}

```

### 5.3 Test Results

Ένα shell script που βρίσκεται στον φάκελο process\_data\_visualization αντιγράφει τα δεδομένα από το kernel debug trace pipe σε ένα αρχείο csv ώστε όλες οι χρήσιμες πληροφορίες να είναι αποθηκευμένες σε αυτό το αρχείο. Το csv αυτό χρησιμοποιείται και στην δημιουργία των γραφημάτων από το Python script.

Το shell script που αντιγράφει τα αποτελέσματα στο csv είναι το παρακάτω:

```

#!/bin/sh

OUTPUT_FILE="hvf_log.csv"

echo "pid,init_sched_value,turnaround_time,wait_time,computation_time,response_time" > "$OUTPUT_FILE"

cat /sys/kernel/debug/tracing/trace | grep "hvf_task_terminated" | \
awk -F, '{ print $2,$3,$4,$5,$6,$7 }' >> "$OUTPUT_FILE"

```

τρέχοντας το στην εικονική μηχανή αμέσως μετά από την εκτέλεση του testbench μου δίνεται ως αποτέλεσμα το παρακάτω csv αρχείο.

```

process_data_visualization - no log.txt
1 pid,init_sched_value,turnaround_time,wait_time,computation_time,response_time
2 643,98,16754,15931,823,1
3 644,85,29546,27986,1646,99
4 645,88,46017,43554,2463,275
5 646,75,63625,60344,3281,364
6 647,78,73394,69299,4895,457
7 648,65,86512,81592,4926,536
8 649,68,95697,89968,5737,610
9 650,55,108764,102206,6558,754
10 651,58,117188,109815,7373,818
11 652,45,125966,117765,8191,877
12 653,48,134071,125957,9814,931
13 654,35,144618,134782,9836,989
14 655,38,151165,148589,10656,1024
15 656,25,156116,144648,11476,1063
16 657,28,159625,147331,12294,1218
17 658,15,164869,158955,13114,1380
18 659,18,168652,152715,13937,1445
19 660,5,169797,155849,14748,1633
20 661,0,171537,155967,15576,2188
21 662,0,187167,178632,16535,2730
22

```

Το python script έπειτα διαβάζει το αρχείο csv που παράχθηκε και παράγει τα παρακάτω γραφήματα:




Figure 1: Χρόνος Ολοκλήρωσης συναρτήσεως αρχικού σκορ

Είναι εύκολο να παρατηρήσουμε ότι όπως ήταν αναμενόμενο οι διεργασίες με το μεγαλύτερο σκορ τείνουν να ολοκληρώνονται σε μικρότερο χρόνο.




Figure 2: Χρόνος Αναμονής συναρτήσεως αρχικού σκορ

Είναι εύκολο να παρατηρήσουμε ότι όπως ήταν αναμενόμενο οι διεργασίες με το μεγαλύτερο σκορ τείνουν να περιμένουν στην ουρά λιγότερο χρόνο.




Figure 3: Χρόνος Εκτέλεσης συναρτήσεως αρχικού σκορ

Είναι εύκολο να παρατηρήσουμε ότι όπως ήταν αναμενόμενο οι διεργασίες με το μεγαλύτερο σκορ τείνουν να χρειάζονται μικρότερο χρόνο για να εκτελεστούν.




Figure 4: Χρόνος απόδοσης συναρτήσεως αρχικού σκορ

Είναι εύκολο να παρατηρήσουμε ότι είναι απόλυτα σχετικό με το scheduling score ο χρόνος απόδοσης που δίνεται ως αποτέλεσμα και με την αύξησή του χρόνος απόδοσης μειώνεται σταδιακά όπως ήταν αναμενόμενο ακολουθώντας το μοτίβο των υπόλοιπων μετρικών.

Ο κώδικας του Python script που παρήγαγε τα γραφήματα βρίσκεται παρακάτω:

```
import pandas as pd
import sys
import mplcursors
import string
import matplotlib
matplotlib.use('TkAgg')
import matplotlib.pyplot as plt

# Προσοχή θέλει installation pandas

def readcsv(filename):
    df=pd.read_csv(filename)

    tuples=df.apply(lambda row: tuple(row), axis=1)
    return tuples

def creatediagram(x_axis,y_axis,PID,title,x_label,y_label):
    bars = plt.bar(x_axis, y_axis, color='red')

    cursor = mplcursors.cursor(hover=mplcursors.HoverMode.Transient)

    @cursor.connect("add")
    def on_add(sel):
        x, y, width, height = sel.artist[sel.index].get_bbox().bounds
        sel.annotation.set(text="PID: "+ str(PID[sel.index]),
                            position=(0, 20), anncoords="offset points")
        sel.annotation.xy = sel.artist[sel.index].get_xy()
        sel.annotation.xy = (
            sel.artist[sel.index].get_x() + sel.artist[sel.index].get_width() / 2,
            sel.artist[sel.index].get_height()
        )

    plt.xlabel(x_label)
    plt.ylabel(y_label)
    plt.title(title)
    plt.show()

filename=sys.argv[1]

read=readcsv(filename)
processID=[]
init_values=[] #always in x axis

#always in y axis
turnaround_time=[]
wait_time=[]
computation_time=[]
response_time=[]

for i in range (len(read)):
    processID.append(read[i][0])
    init_values.append(float(read[i][1]))
    turnaround_time.append(float(read[i][2]))
    wait_time.append(float(read[i][3]))
    computation_time.append(float(read[i][4]))
    response_time.append(float(read[i][5]))

#create diagrams

creatediagram(init_values,turnaround_time,processID,"Check Turnaround","init values","turnaround time")
creatediagram(init_values,wait_time,processID,"Wait timing","init values","wait_time")
creatediagram(init_values,computation_time,processID,"Computation","init values","Computation_time")
creatediagram(init_values,response_time,processID,"Response","init values","response_time")
```

μέσω αυτού του script διαβάζεται το hvf\_log.csv και παράγονται τα αντίστοιχα γραφήματα που παρουσιάζονται παραπάνω.

## 6 Έκδοση 2η: Επιλογή CPU και Process-Migration

Σε συστήματα πολλαπλών πυρήνων (SMP systems), όπως είναι σχεδόν όλα οι σημερινοί υπολογιστές (πλην κάποιων ενσωματωμένων μικροεπεξεργαστικών συστημάτων) υποστηρίζεται η αλλαγή του cpu στον οποίο εκτελείται η κάθε διεργασία κατά την επανεκκίνηση τους (όταν ξεκινούν να εκτελούνται ξανά από κατάσταση sleep, δηλαδή σε wakeups). Η διαδικασία αλλαγής επεξεργαστή εκτέλεσης ονομάζεται process-migration και καθορίζεται σε μεγάλο βαθμό από την scheduling-class που διαχειρίζεται την κάθε διεργασία.

Στις scheduling-classes του Linux Kernel υπάρχουν 3 βασικές συναρτήσεις που πρέπει να υλοποιηθούν για να υποστηρίζεται process migration. Οι συναρτήσεις αυτές είναι οι παρακάτω:

- `balance()`, καλείται όταν ένας επεξεργαστής είναι idle για να κριθεί αν θα πρέπει να έλθουν tasks προς εκείνον.
- `select_task_rq()`, καλείται κάθε φορά που μια διεργασία πρόκειται να αλλάξει CPU κατά την εκτέλεσή της (συνήθως αυτό γίνεται σε wakeup events).
- `migrate_task_rq()`, καλείται αμέσως πριν την διεξαγωγή του πραγματικού migration από την μια cpu στην καινούρια της διεργασίας, ώστε να αρχικοποιηθούν κατάλληλα τα στοιχεία της εκάστοτε scheduling κλάσης πρώτου εκτελεστεί το ίδιο το migration.

Στον δικό μου χρονοπρογραμματιστή (αλγόριθμο highest-value-first) επιλέχθηκε να υλοποιηθεί η εξής λογική:

- Αντιγράφουμε σε ένα array ζεύγη (`<cpu-id>`, `<πλήθος τρέχοντων διεργασιών>`) και ταξινομούμε αυτό το array βάσει του δεύτερου στοιχείου κάθε ζεύγους (του φόρτου δηλαδή του εκάστοτε επεξεργαστή).
- Γνωρίζουμε ότι κάθε διεργασία έχει scheduling score από 0 έως 100 και ότι όσο μεγαλύτερο το σκορ τόσο λιγότερος είναι και ο χρόνος εκτέλεσης (συνεπώς τόσο ελαφρύτερη είναι και η διεργασία).
- Συνεπώς αντιστοιχίζουμε χωρίζοντας σε chunks τους επεξεργαστές με χαμηλό φόρτο στα tasks με χαμηλότερο scheduling value ενώ τα tasks που είναι γρήγορα (δηλαδή έχουν υψηλό scheduling value) πηγαίνουν σε πιο φορτωμένους cpus.
- Αν μια cpu είναι idle για μεγάλο διάστημα τότε σε περίπτωση που υπάρχουν tasks μπορούμε να φερίουμε προς εκείνη (αυτό προστάζει η συνάρτηση `balance()`).

Αυτή η λογική λοιπόν υλοποιείται και στις παρακάτω 3 συναρτήσεις που παρατίθενται. Η `migrate_task_rq_hvf` καταγράφει στο trace-buffer τις αλλαγές cpu που εκτελεί κάθε διεργασία. Πρατείθεται η έξοδος που παρατηρείται στο buffer παρακάτω:

```

361 static int select_task_rq_hvf(struct task_struct *p, int prev_cpu, int flags)
362 {
363     int new_cpu = prev_cpu;
364
365     if (!!(flags & (WF_TTWU | WF_FORK)))
366         goto out;
367
368     int cpu_len = p->nr_cpus_allowed;
369     if (cpu_len == 1)
370         goto out;
371
372     //create the array of loads
373     struct cpu_load *loads = malloc_array(cpu_len, sizeof(struct cpu_load), GFP_KERNEL);
374     sort_cpu_loads_in_mask(p->cpus_ptr, loads, cpu_len);
375     struct sched_hvf_entity *se_hvf = &p->hvf;
376     new_cpu = get_right_cpu(loads, se_hvf->curr_sched_value, cpu_len);
377     kfree(loads);
378
379 out:
380     p->hvf_prev_cpu = prev_cpu;
381     p->hvf_curr_cpu = new_cpu;
382     return new_cpu;
383 }
384
385 static void migrate_task_rq_hvf(struct task_struct *p, int new_cpu)
386 {
387     p->hvf_curr_cpu = new_cpu;
388     int prev_cpu = p->hvf_prev_cpu;
389
390     struct rq *prev_rq = cpu_rq(prev_cpu);
391     struct rq *new_rq = cpu_rq(new_cpu);
392
393     unsigned int prev_running = prev_rq->nr_running;
394     unsigned int new_running = new_rq->nr_running;
395
396     long curr_value = p->hvf_curr_sched_value;
397
398     if (prev_cpu != new_cpu)
399     {
400         trace_printk(
401             "hvf_task_migrates: %d value: %ld from %d, %d running to %d, %d running\n",
402             p->pid,
403             curr_value,
404             prev_cpu,
405             prev_running,
406             new_cpu,
407             new_running
408         );
409     }
410
411     static inline int balance_hvf(struct rq *rq, struct task_struct *prev, struct rq_flags *rf)
412     {
413         return sched_hvf_runnable(rq);
414     }
415
416 #endif /* CONFIG_SMP */

```

Figure 5: Υλοποίηση βασικών SMP συναρτήσεων

```

root@alekpc/home/alekan/kernel-stuff/linux-test_vn
alekan@alekan-standardpc:~$ sudo cat /sys/kernel/debug/tracing/trace | grep "hvf_task_migrates"
schedTest-629 [002] d..3. 18.810097: migrate_task_rq_hvf: hvf_task_migrates: 631 value: 54 from 2, 3 running to 1, 1 running
schedTest-631 [001] d..3. 18.820092: migrate_task_rq_hvf: hvf_task_migrates: 638 value: 19 from 1, 2 running to 0, 0 running
schedTest-638 [000] d..3. 18.820451: migrate_task_rq_hvf: hvf_task_migrates: 639 value: 14 from 1, 2 running to 3, 0 running
schedTest-639 [003] d..3. 18.821433: migrate_task_rq_hvf: hvf_task_migrates: 637 value: 24 from 1, 2 running to 0, 1 running
schedTest-640 [003] d..3. 18.848087: migrate_task_rq_hvf: hvf_task_migrates: 640 value: 9 from 2, 3 running to 3, 1 running
schedTest-641 [001] d..3. 18.868499: migrate_task_rq_hvf: hvf_task_migrates: 641 value: 4 from 2, 3 running to 1, 2 running
schedTest-642 [000] d..3. 18.883086: migrate_task_rq_hvf: hvf_task_migrates: 642 value: 0 from 1, 3 running to 0, 2 running
schedTest-642 [000] d..3. 19.032087: migrate_task_rq_hvf: hvf_task_migrates: 627 value: 74 from 0, 3 running to 2, 3 running
schedTest-627 [002] d..3. 19.042089: migrate_task_rq_hvf: hvf_task_migrates: 643 value: 0 from 2, 4 running to 3, 2 running
schedTest-628 [000] d..3. 19.071085: migrate_task_rq_hvf: hvf_task_migrates: 636 value: 79 from 3, 3 running to 0, 4 running
schedTest-626 [000] d..3. 19.113496: migrate_task_rq_hvf: hvf_task_migrates: 630 value: 59 from 1, 3 running to 2, 4 running
schedTest-630 [002] d..3. 19.156086: migrate_task_rq_hvf: hvf_task_migrates: 632 value: 49 from 1, 3 running to 3, 3 running
schedTest-632 [003] d..3. 19.163495: migrate_task_rq_hvf: hvf_task_migrates: 634 value: 39 from 1, 3 running to 3, 4 running
schedTest-634 [003] d..3. 19.274581: migrate_task_rq_hvf: hvf_task_migrates: 635 value: 34 from 1, 3 running to 3, 5 running
schedTest-635 [003] d..3. 19.322515: migrate_task_rq_hvf: hvf_task_migrates: 636 value: 29 from 1, 3 running to 0, 5 running
alekan@alekan-standardpc:~$

```

Figure 6: Έξοδος στην αλλαγή CPU. Παρατηρούμε ότι όσο μικρότερη η τιμή τόσο πιο πιθανό είναι η διεργασία να κάνει migrate σε cpu με λιγότερες διεργασίες από τον προηγούμενο

## 7 Sources and Citations

Πηγές πληροφόρησης που με βοήθησαν στην ανάπτυξη αυτού του πρότζεκτ είναι οι παρακάτω:

- [Linux Kernel Documentation](#)
- [Linux Kernel Development](#) (Book by Robert Love)
- [Linux Kernel Programming](#) (Book by Kaiwan Billimoria)
- Εύκολο browsing του linux kernel source code